

Proyecto AURA

Recomendaciones de Hardware



Integrantes:

Bruno Albín
Ignacio Villarreal
Santiago Aurrecochea
Emiliano Fau

Tutor:

Bernardo Rychtenberg

26 de junio de 2026

Índice

1	Riesgo Asociado	1
2	Recomendaciones para el servidor principal	1
2.1	CPU	1
2.2	GPU	1
2.3	Memoria RAM	2
2.4	Almacenamiento	2
2.5	Red	2
3	Recomendaciones para los equipos cliente	3
4	Justificación	3

1. Riesgo Asociado

Esta sección forma parte del plan de mitigación del riesgo identificado como “**Insuficiencia de capacidad de hardware**” en el registro de riesgos del proyecto AURA. El objetivo es establecer los requisitos mínimos y recomendados de hardware para que el sistema opere correctamente en la infraestructura propia de la Fuerza Aérea del Uruguay (FAU), considerando que el modelo de lenguaje (LLM) corre de forma local y que se estiman menos de 20 usuarios concurrentes.

2. Recomendaciones para el servidor principal

El servidor principal es el equipo que ejecuta el backend, el modelo LLM y la base de datos PostgreSQL con PGVector. Es el componente crítico del sistema.

2.1. CPU

Componente	Mínimo	Recomendado	Notas
Procesador	8 núcleos / 16 hilos	16 núcleos / 32 hilos	El LLM usa CPU si no hay GPU suficiente. Más núcleos mejoran la inferencia y el procesamiento paralelo de consultas.
Arquitectura	x86-64	x86-64 (AMD EPYC o Intel Xeon)	Procesadores de servidor preferibles por su soporte de memoria ECC y canales de memoria múltiples.
Frecuencia	2.5 GHz base	3.0 GHz base o superior	Mayor frecuencia mejora la latencia en consultas individuales.

2.2. GPU

Componente	Mínimo	Recomendado	Notas
VRAM	16 GB	24 GB o más	16 GB permite Llama 3 8B en FP16. Para modelos de 13B se necesitan 24 GB. Modelos de 70B requieren múltiples GPUs o cuantización Q4.
Modelo GPU	NVIDIA RTX 3090 / A4000	NVIDIA A6000 / RTX 4090 / A100	Se recomienda hardware NVIDIA por compatibilidad con CUDA, requerido por los frameworks de inferencia (llama.cpp, vLLM, Ollama).
Cantidad	1 GPU	2 GPU (NVLink o PCIe)	2 GPU permite modelos más grandes o mayor throughput con múltiples usuarios concurrentes.

2.3. Memoria RAM

Componente	Mínimo	Recomendado	Notas
Capacidad RAM	32 GB	64 GB	El sistema operativo, el backend, PostgreSQL y el proceso de inferencia compiten por RAM. Con menos de 32 GB se producen swaps que afectan el rendimiento.
Tipo	DDR4 ECC	DDR5 ECC	ECC (Error Correcting Code) previene corrupción silenciosa de datos.
Frecuencia	2666 MHz	3200 MHz o superior	Mayor ancho de banda de memoria mejora la transferencia de datos al modelo.

2.4. Almacenamiento

Componente	Mínimo	Recomendado	Notas
Disco del sistema	512 GB SSD NVMe	1 TB SSD NVMe	El sistema operativo, los modelos LLM y los índices vectoriales deben estar en SSD. Un modelo Llama 3 8B ocupa aprox. 16 GB; un modelo 70B ocupa aprox. 140 GB.
Disco de datos	2 TB HDD o SSD	4 TB SSD SATA	Para almacenar los documentos de la FAU, backups de la base de datos y logs del sistema.
RAID	RAID 1 (espejo)	RAID 10	Redundancia mínima para un servidor de producción en una institución como la FAU.

2.5. Red

Componente	Mínimo	Recomendado	Notas
Interfaz de red	1 Gbps	10 Gbps	Para la transferencia de documentos grandes y comunicación con clientes.
Redundancia	1 NIC	2 NIC (bonding)	Doble interfaz para alta disponibilidad y mayor throughput.

3. Recomendaciones para los equipos cliente

Componente	Mínimo	Recomendado	Notas
CPU	Intel Core i3 / AMD Ryzen 3 (8ª gen o superior)	Intel Core i5 / AMD Ryzen 5	Cualquier equipo moderno es suficiente para el frontend.
RAM	8 GB	16 GB	Para navegadores con varias pestañas abiertas simultáneamente.
Almacenamiento	256 GB SSD	256 GB SSD	Solo para el sistema operativo y el navegador. No se almacenan datos del sistema localmente.
Resolución	1366 × 768	1920 × 1080	La interfaz está diseñada para resoluciones Full HD.
Red	100 Mbps LAN	1 Gbps LAN	Conexión a la red interna de la FAU. El sistema no requiere acceso a internet.

4. Justificación

Las recomendaciones anteriores se fundamentan en la evaluación comparativa de modelos de lenguaje documentada junto al código del sistema, se detalla el tamaño, los parámetros, la ventana de contexto y los requerimientos de memoria de los modelos considerados (familias Gemma, Qwen, Llama, Mistral y DeepSeek-R1, incluyendo variantes cuantizadas Q4 que corren en 8 GB de VRAM). Esa tabla justifica directamente los rangos de VRAM y almacenamiento recomendados en esta sección.

El despliegue contempla ambas configuraciones mediante Docker Compose:

- **Una variante GPU** de los servicios, con aceleración CUDA para la inferencia y la generación de embeddings.
- **Una variante CPU**, que permite operar el sistema con modelos livianos a costa de mayores tiempos de respuesta.

Esta dualidad es, en sí misma, una medida de mitigación del riesgo de hardware: le permite a la FAU comenzar a operar con equipamiento existente y escalar a una configuración GPU cuando el volumen de uso lo justifique.