

Plan de Proyecto IV - FINAL

Introducción

El presente documento establece el plan de trabajo para el desarrollo de un sistema de gestión documental basado en Inteligencia Artificial destinado a la Fuerza Aérea del Uruguay. La FAU es una institución la cual contiene diversas escuelas y comandos que, además de cumplir con tareas de formación académica, diariamente gestionan un voluminoso conjunto de documentos críticos para sus operaciones. Actualmente dichos documentos se encuentran dispersos y no existe un mecanismo eficiente para manejarlos o consultarlos, por lo que el acceso a la información resulta complejo.

Con el objetivo de modernizar sus tecnologías y consolidarse como una institución profesional y tecnológicamente avanzada, la FAU se plantea la implantación de un sistema que utilice modelos de lenguaje (LLMs) para procesar, analizar y administrar documentos. El sistema debe ser capaz de comprender la información y relacionarla de manera contextual, devolviendo respuestas adecuadas a las consultas de los usuarios.

Este plan describe las etapas, tareas y la forma en que el equipo gestionará el proyecto a lo largo de su ciclo de vida. También se establecen los objetivos e hitos de cada fase y los criterios de aceptación acordados con el cliente. El plan servirá de guía para asignar responsabilidades, coordinar actividades y dar seguimiento al cronograma.

Esta última versión del Plan de Proyecto actualiza la planificación realizada en septiembre de 2025, incorporando el estado actual del proyecto, ajustes en el alcance, una descripción más detallada de la gestión ágil, la actualización del registro de riesgos y un plan de calidad y criterios de aceptación más medibles. Este documento se complementa con el Plan de Visión, el Plan de Pruebas y el documento de Arquitectura del sistema.

Estado Actual del Proyecto

A la fecha de elaboración de esta versión del plan, el proyecto se encuentra en la fase de cierre de Construcción. Se ha completado el desarrollo e integración de los siete microservicios del backend (Auth, Chat, Document Collection, Document Processing, LLM, Notification y Gateway) con persistencia y colas avanzadas (PostgreSQL + pgvector, Neo4j, MinIO, Redis y RabbitMQ) y soporte para observabilidad (Prometheus, Grafana y Phoenix). El frontend está completamente implementado en Angular 20, siguiendo el sistema de diseño de la aplicación.

Sobre la base de estos avances, el sistema se encuentra listo para iniciar las pruebas de aceptación y la fase de Transición hacia la infraestructura definitiva de la FAU, cumpliendo con el objetivo principal de ofrecer una herramienta centralizada y robusta para la gestión y consulta inteligente de su documentación crítica.

Gestión del Proyecto

La gestión del proyecto se basa en metodologías ágiles, utilizando iteraciones cortas para planificar, desarrollar y revisar el trabajo de forma incremental. Cada iteración produce un incremento funcional del sistema que puede ser revisado por el equipo y por la FAU.

Organización del Equipo

En cuanto a la organización del equipo, este se distribuye en roles complementarios según las competencias de cada integrante: gestión de proyectos y análisis de requisitos, diseño de interfaces y mockups, desarrollo frontend, desarrollo backend, integración de la solución de IA, bases de datos, pruebas y documentación. Varios miembros asumen más de un rol, lo que permite una mayor flexibilidad para cubrir las distintas actividades del proyecto.

Enfoque Ágil y Reuniones

Cada iteración comienza con una reunión de planificación, en la que se seleccionan las historias de usuario a abordar, se descomponen en tareas técnicas y se estiman en horas. A lo largo de la iteración se realizan reuniones de seguimiento semanales para revisar el avance, identificar impedimentos y, si es necesario, ajustar el alcance comprometido. Al final de cada iteración se lleva a cabo una revisión, donde se presentan los incrementos desarrollados, y una breve retrospectiva interna para identificar mejoras en la forma de trabajo.

Los cambios o nuevos requisitos emergentes se analizan con el equipo y se incorporan al backlog, donde se priorizan según su valor para la FAU y su impacto en el cronograma. De esta manera, el plan se mantiene alineado con las necesidades reales del cliente.

Al cierre de cada iteración se comparte con la FAU el estado del proyecto, los hitos alcanzados y los próximos pasos, de forma de obtener feedback temprano y validar que la solución evoluciona en línea con sus expectativas y criterios de aceptación.

Comunicación del Equipo

La comunicación interna del equipo se apoya en las ceremonias ágiles descritas (planificación, seguimiento semanal, revisión y retrospectiva) y en las herramientas de gestión (Jira para el seguimiento del trabajo y Confluence para la documentación de decisiones y minutas). La comunicación con la FAU se gestiona a través del rol de gestión de proyecto, mediante

reuniones de revisión al cierre de cada iteración y la entrega de informes de estado. Las decisiones técnicas relevantes y los acuerdos con el cliente se registran en Confluence para mantener trazabilidad. Dentro del equipo nos comunicamos usando mensajería (WhatsApp) y videollamadas (Google Meet, Discord).

Gestión de la Configuración

El código fuente se administra en dos repositorios Git:

- `aura-backend` - microservicios, infraestructura Docker/Docker Compose, scripts y documentación técnica (incluida la comparativa de modelos LLM y los diagramas de arquitectura y de datos).
- `aura-frontend` - aplicación Angular (código fuente localizado dentro de la carpeta `application/`).

Los cambios se integran mediante revisión de código entre pares (pull/merge requests) antes de su incorporación a la rama principal, lo que constituye uno de los mecanismos de aseguramiento de calidad definidos en este plan: ningún cambio llega a la rama de integración sin la aprobación de al menos un revisor distinto del autor. Las versiones de las dependencias quedan declaradas en los archivos correspondientes de cada servicio (archivo `requirements.txt` en la raíz o dentro de la carpeta `requirements/` para microservicios de Python, y `package.json` en la carpeta `application/` del frontend). La configuración de cada entorno se gestiona mediante variables de entorno usando archivos `.env` y `.env.docker`. Para asegurar la confidencialidad de los datos sensibles, el repositorio solo incluye plantillas de configuración de referencia (como `.env.example`), mientras que las credenciales de producción y datos sensibles reales se mantienen fuera de Git.

Estrategia de ramas

El equipo trabaja sobre una rama principal llamada “main” estable de integración, derivando ramas de trabajo por funcionalidad o historia de usuario que se reintegran mediante revisión entre pares. Se inicia una nueva rama con la palabra “feature/” o “fix/” dependiendo si se va a trabajar una funcionalidad nueva o si se va a aplicar una corrección de una funcionalidad existente, esto seguido del nombre de la tarea breve que se va a trabajar.

Gestión de Riesgos y Calidad

El proyecto mantiene un registro de riesgos formal, detallado en el documento de Riesgos, que clasifica los riesgos de sistema y de proyecto según su probabilidad e impacto y define para cada uno sus acciones de mitigación. Dicho registro se revisa periódicamente al inicio de cada iteración, momento en el cual se actualiza el estado de cada riesgo y se reprograman las

acciones de mitigación pendientes, planificadas preferentemente en las primeras iteraciones para reducir la exposición temprana.

Hitos y Objetivos del Proyecto

Los hitos del proyecto se organizan siguiendo las fases del ciclo de vida del proceso unificado (Incepción, Elaboración, Construcción y Transición), cada fase puede contener una o más iteraciones, y dentro de cada una se establecen objetivos concretos que permiten medir el avance y mitigar riesgos.

En esta tercera versión del plan se mantiene la estructura original de fases e iteraciones, pero se refinan los objetivos para alinear mejor el trabajo con el estado actual del proyecto y con las necesidades priorizadas por la FAU. De esta forma, la tabla sirve tanto como guía de planificación como referencia para el seguimiento del progreso.

Fase	Iteración	Objetivos e hitos principales
Incepción	I1	- Definir el alcance y los requisitos iniciales mediante el análisis del contexto y los problemas identificados en la FAU, consolidando los requerimientos funcionales y no funcionales más relevantes. - Especificar los principales módulos del sistema (interfaz, gestión de documentos, IA y usuarios) y sus responsabilidades a alto nivel. - Identificar los riesgos críticos del proyecto (técnicos, de IA, de seguridad y de alineación con el cliente) y elaborar un primer plan de mitigación.
Elaboración	E1	- Refinar los requisitos mediante reuniones de trabajo con el equipo y con representantes de la FAU, priorizando los flujos de uso más críticos. - Elaborar prototipos de las principales pantallas para validar la experiencia de usuario. - Detallar los casos de uso principales y definir las interacciones entre módulos, dejando trazabilidad con las historias de usuario del backlog.

	E2	• Implementar el módulo central de gestión de documentos, permitiendo cargar, almacenar, indexar y consultar documentos. • Desarrollar el módulo de gestión de usuarios y roles, junto con su base de datos, habilitando autenticación y permisos diferenciados según el tipo de usuario. • Generar datos de prueba y escenarios básicos que sirvan luego para validar el comportamiento del sistema y del módulo de IA.
	E3	• Implementar el módulo de IA encargado de procesar y relacionar los documentos, integrándolo con la base de datos vectorial definida en el documento de Arquitectura. • Completar la funcionalidad de la interfaz gráfica en los flujos principales (búsqueda, visualización de documentos y administración básica) y realizar una primera ronda de pruebas de usabilidad. • Preparar el plan de pruebas de la aplicación completa, definiendo tipos de pruebas, responsabilidades y criterios de aceptación por iteración.
	Construcción	
	C1	• Desarrollar las funcionalidades restantes necesarias para completar el alcance definido en el MVP (auditoría, filtros avanzados de búsqueda, gestión de metadatos, etc.). • Ajustar y optimizar el desempeño del sistema para cumplir con los requisitos no funcionales de tiempo de respuesta y uso de recursos.
	C2	• Integrar y validar los mecanismos de seguridad y cumplimiento definidos con la FAU (control de accesos, manejo de roles, auditoría básica de acciones). • Ejecutar pruebas de carga y estrés para garantizar que el sistema soporte el volumen de

		documentos y consultas estimado, documentando los resultados y las mejoras aplicadas.
	C3	• Realizar pruebas de aceptación con usuarios representativos de la FAU, recogiendo feedback sobre usabilidad, calidad de las respuestas de la IA y adecuación a los procesos actuales. • Corregir los defectos identificados en las pruebas y completar la documentación técnica, así como los manuales de usuario preliminares.
Transición	T1	• Desplegar el sistema en la infraestructura acordada con la FAU. • Configurar los servicios necesarios para la operación (bases de datos, almacenamiento de documentos, monitoreo básico). • Capacitar al personal en el uso de la aplicación y en los procedimientos básicos de administración. • Realizar la entrega formal con todos los manuales y evidencias de pruebas.

Criterio de Aceptación del Proyecto

El proyecto será considerado aceptado por la FAU cuando, al finalizar la fase de Transición, se verifique el cumplimiento de los siguientes criterios de aceptación:

- **Cobertura funcional:** El sistema implementa todas las historias de usuario marcadas como obligatorias en el backlog y permite cargar, gestionar y consultar documentos provenientes de las distintas áreas de la FAU. Los usuarios autenticados pueden realizar búsquedas en lenguaje natural y obtener accesos a los documentos y respuestas generadas por la IA de forma coherente con los requisitos definidos.
- **Calidad de las respuestas de la IA:** En las pruebas de aceptación con usuarios de la FAU, al menos el 80% de las consultas es calificado como "relevante" o "muy relevante" en cuanto a pertinencia de la respuesta y de los documentos sugeridos, sin exponer información a usuarios que no cuenten con los permisos correspondientes. Esto se mide haciendo uso del mecanismo de valoración de respuestas integrado en el sistema (calificación positiva o negativa de cada respuesta, con motivo en caso de valoración negativa) y su pantalla de

analítica de retroalimentación (feedback-analytics), que agrega las valoraciones por ventanas de tiempo y detalla los motivos. El umbral del 80% se calcula como la proporción de respuestas con valoración positiva sobre el total de respuestas valoradas en el período de aceptación.

- **Rendimiento y experiencia de uso:** Para el volumen de documentos y usuarios definido en el Plan de Pruebas (menos de 20 usuarios concurrentes), el tiempo medio de respuesta de las búsquedas se mantiene menor o igual a 30 segundos en condiciones normales de carga, y no se registran problemas de usabilidad graves que impidan operar el sistema. Para medir esto se utilizan las métricas de latencia expuestas por los servicios y los tableros de Prometheus, Grafana y Phoenix incluidos en el despliegue de observabilidad, asimismo las medidas sobre el hardware recomendado en este plan. El criterio aplica al tiempo de recuperación de fragmentos y respuesta del sistema, los tiempos de procesamiento del modelo dependen del hardware (CPU vs GPU) y se reportan por separado.
- **Seguridad y control de accesos:** El sistema exige autenticación para todos los usuarios y aplica correctamente los roles y permisos definidos. Las pruebas de autorización demuestran que cada tipo de usuario solo puede acceder a las funcionalidades y documentos que le corresponden.
- **Despliegue e infraestructura operativa:** La solución se despliega en la infraestructura acordada con la FAU y queda lista para operar en sus servidores o entorno equivalente, con los servicios necesarios configurados (bases de datos, almacenamiento de documentos, copias de respaldo y monitoreo).
- **Documentación y capacitación:** El equipo entrega los manuales de administración y uso del sistema, junto con la documentación técnica necesaria para futuros desarrolladores. Además, se realiza un plan de capacitación junto a varias instancias para el personal designado por la FAU.
- **Gestión de defectos:** Al cierre de la fase de Transición no permanecen abiertos defectos clasificados como críticos o de alta severidad en el sistema, y las incidencias de severidad media o baja han sido evaluadas y aceptadas por la FAU para ser resueltas en iteraciones posteriores, si correspondiera.

Recomendaciones de Hardware

Riesgo asociado

Esta sección forma parte del plan de mitigación del riesgo identificado como “Insuficiencia de capacidad de hardware” en el registro de riesgos del proyecto AURA. El objetivo es establecer los requisitos mínimos y recomendados de hardware para que el sistema opere correctamente

en la infraestructura propia de la Fuerza Aérea del Uruguay, considerando que el modelo de lenguaje (LLM) corre de forma local y que se estiman menos de 20 usuarios concurrentes.

Recomendaciones para el servidor principal

El servidor principal es el equipo que ejecuta el backend, el modelo LLM y la base de datos PostgreSQL con PGVector. Es el componente crítico del sistema.

CPU

Componente	Mínimo	Recomendado	Notas
Procesador	8 núcleos / 16 hilos	16 núcleos / 32 hilos	El LLM usa CPU si no hay GPU suficiente. Más núcleos mejoran la inferencia y el procesamiento paralelo de consultas.
Arquitectura	x86-64	x86-64 (AMD EPYC o Intel Xeon)	Procesadores de servidor preferibles por su soporte de memoria ECC y canales de memoria múltiples.
Frecuencia	2.5 GHz base	3.0 GHz base o superior	Mayor frecuencia mejora la latencia en consultas individuales.

GPU

Componente	Mínimo	Recomendado	Notas
VRAM	16 GB	24 GB o más	16 GB permite Llama 3 8B en FP16. Para modelos de 13B se necesitan 24 GB. Modelos de 70B requieren múltiples GPUs o cuantización Q4.

Modelo GPU	NVIDIA RTX 3090 / A4000	NVIDIA A6000 / RTX 4090 / A100	Se recomienda hardware NVIDIA por compatibilidad con CUDA, requerido por los frameworks de inferencia (llama.cpp, vLLM, Ollama).
Cantidad	1 GPU	2 GPU (NVLink o PCIe)	2 GPU permite modelos más grandes o mayor throughput con múltiples usuarios concurrentes.

Memoria RAM

Componente	Mínimo	Recomendado	Notas
Capacidad RAM	32 GB	64 GB	El sistema operativo, el backend, PostgreSQL y el proceso de inferencia compiten por RAM. Con menos de 32 GB se producen swaps que afectan el rendimiento.
Tipo	DDR4 ECC	DDR5 ECC	ECC (Error Correcting Code) previene corrupción silenciosa de datos.
Frecuencia	2666 MHz	3200 MHz o superior	Mayor ancho de banda de memoria mejora la transferencia de datos al modelo.

Almacenamiento

Componente	Mínimo	Recomendado	Notas
Disco del sistema	512 GB SSD NVMe	1 TB SSD NVMe	El sistema operativo, los modelos LLM y los índices vectoriales deben estar en SSD. Un modelo Llama 3 8B ocupa aprox. 16 GB; un modelo 70B ocupa aprox. 140 GB.
Disco de datos	2 TB HDD o SSD	4 TB SSD SATA	Para almacenar los documentos de la FAU, backups de la base de datos y logs del sistema.
RAID	RAID 1 (espejo)	RAID 10	Redundancia mínima para un servidor de producción en una institución como la FAU.

Red

Componente	Mínimo	Recomendado	Notas
Interfaz de red	1 Gbps	10 Gbps	Para la transferencia de documentos grandes y comunicación con clientes.
Redundancia	1 NIC	2 NIC (bonding)	Doble interfaz para alta disponibilidad y mayor throughput.

Recomendaciones para los equipos cliente

Componente	Mínimo	Recomendado	Notas

CPU	Intel Core i3 AMD Ryzen 3 (8ª gen o superior)	Intel Core i5 / AMD Ryzen 5	Cualquier equipo moderno es suficiente para el frontend.
RAM	8 GB	16 GB	Para navegadores con varias pestañas abiertas simultáneamente.
Almacenamiento	256 GB SSD	512 GB SSD	Solo para el sistema operativo y el navegador. No se almacenan datos del sistema localmente.
Resolución	1366 × 768	1920 × 1080	La interfaz está diseñada para resoluciones Full HD.
Red	100 Mbps LAN	1 Gbps LAN	Conexión a la red interna de la FAU. El sistema no requiere acceso a internet.

Justificación

Las recomendaciones anteriores se fundamentan en la evaluación comparativa de modelos de lenguaje documentada junto al código del sistema, se detalla el tamaño, los parámetros, la ventana de contexto y los requerimientos de memoria de los modelos considerados (familias Gemma, Qwen, Llama, Mistral y DeepSeek-R1, incluyendo variantes cuantizadas Q4 que corren en 8 GB de VRAM). Esa tabla justifica directamente los rangos de VRAM y almacenamiento recomendados en esta sección.

El despliegue contempla ambas configuraciones mediante Docker Compose:

- Una variante GPU de los servicios, con aceleración CUDA para la inferencia y la generación de embeddings.
- Una variante CPU, que permite operar el sistema con modelos livianos a costa de mayores tiempos de respuesta.

Esta dualidad es, en sí misma, una medida de mitigación del riesgo de hardware: le permite a la FAU comenzar a operar con equipamiento existente y escalar a una configuración GPU cuando

el volumen de uso lo justifique.