

Plan de Visión IV - FINAL

Introducción

El propósito de este documento es reunir, analizar y definir las necesidades de alto nivel del usuario y las funcionalidades de AURA. Se enfoca en las capacidades requeridas por los usuarios objetivo y en por qué existen esas necesidades. Los detalles de cómo el sistema satisfará esas necesidades se describen en los casos de uso y en las especificaciones de requerimientos suplementarios.

Definiciones, acrónimos y abreviaciones

- AURA: Asistente unificado de respuesta avanzada.
- FAU: Fuerza Aérea Uruguaya
- IA: Inteligencia artificial
- RFA: Reglamentaciones de la Fuerza Aérea
- EMA: Escuela Militar de Aeronáutica
- ECEMA: Escuela de Comando y Estado Mayor Aéreo
- VPN: Red privada virtual
- RAG: Generación aumentada por recuperación (Retrieval Augmented Generation). Técnica que enriquece las respuestas del modelo de lenguaje con fragmentos recuperados de una base documental propia.
- LLM: Modelo de lenguaje de gran escala (Large Language Model).
- Embedding: Representación vectorial del significado de un texto, utilizada para realizar búsquedas semánticas.
- JWT: Token web JSON (JSON Web Token). Es un mecanismo de autenticación basado en tokens firmados.
- RBAC: Control de acceso basado en roles (Role-Based Access Control).
- MAC: Control de acceso obligatorio basado en niveles de clasificación de seguridad y compartimentos (Mandatory Access Control).
- OCR: Reconocimiento óptico de caracteres (Optical Character Recognition).
- SSE: Eventos enviados por el servidor (Server-Sent Events). Se trata de un canal de notificaciones en tiempo real desde el servidor hacia el cliente.
- WebSocket: Protocolo de comunicación bidireccional en tiempo real entre cliente y servidor.
- API: Interfaz de programación de aplicaciones (Application Programming Interface).
- MVP: Producto mínimo viable (Minimum Viable Product).

- LDAP: Protocolo ligero de acceso a directorios (Lightweight Directory Access Protocol). Es un servicio de directorio donde una organización centraliza identidades de usuario y sus atributos (por ejemplo, rango y departamento).

Referencias

Este documento forma parte del conjunto de documentación de la tesis AURA. Los documentos relacionados son el plan de proyecto, arquitectura, diseño, riesgos, casos de uso (usuario y administrador y plan de pruebas, junto con sus módulos.

Posicionamiento del proyecto

Este proyecto consiste en desarrollar un sistema basado en IA el cual brinde respuestas a consultas acerca de documentos importantes referentes a la FAU. Al momento de consultar, el sistema tendrá en cuenta los permisos del usuario, en base a su rango y departamento, para seleccionar qué información contendrá la respuesta.

Oportunidad de negocios

Este proyecto le brindará a la FAU un avance tecnológico significativo en cuanto a la gestión de documentos, permitiendo un mejor uso del tiempo y esfuerzo del personal, además de alinearla con su misión de mantenerse como una institución profesional y avanzada en el ámbito tecnológico.

Al construir el sistema sobre un modelo de lenguaje ejecutado localmente y una base documental propia, la FAU obtiene una plataforma que no solo localiza información sino que también la sintetiza, genera documentación operativa derivada (reportes y listas de verificación) y habilita el trabajo colaborativo, todo esto sin salir de la infraestructura de la FAU.

Declaración del problema

Actualmente, los funcionarios de la FAU interesados en la información de algún documento (perteneciente a la FAU) deberán tomarse el tiempo y esfuerzo de buscar entre todos los documentos el que necesitan, en ocasiones no teniendo éxito. Este proyecto planea unificar en un sistema todos estos documentos para trivializar la búsqueda de información para todos los interesados mediante consultas en lenguaje natural, y hacerlo respetando los permisos de cada usuario, todo ello con una arquitectura que permite la futura escalabilidad del sistema.

Declaración de posicionamiento del producto

Las características distintivas del producto desarrollado son las siguientes:

- **Procesamiento cognitivo avanzado:** Capacidad de análisis del lenguaje natural en RFAs, órdenes y trabajos académicos, con extracción y estructuración eficiente de información relevante.
- **Análisis relacional:** Identificación automática de conexiones, dependencias y posibles contradicciones entre diferentes documentos institucionales.
- **Interfaz intuitiva:** Sistema de consulta en lenguaje natural que permita al personal obtener respuestas precisas y contextualizadas, citando las fuentes que se utilizaron.
- **Actualización dinámica:** Capacidad de incorporar y procesar nuevos documentos de manera automática (extracción, limpieza, fragmentación y vectorización), manteniendo la base de conocimientos actualizada.
- **Soberanía de los datos:** Todo el procesamiento, incluida la inferencia del modelo de lenguaje, se realiza en infraestructura propia de la FAU, sin enviar información a servicios externos en Internet.

Descripción de usuarios e interesados

Interesados

Oficial

Este usuario engloba a los oficiales de la FAU, estos usuarios planifican, organizan y comandan las operaciones militares, así como toman decisiones estratégicas para cumplir con las misiones asignadas. Son responsables de la planificación estratégica y la toma de decisiones, es decir analizar escenarios, diseñar planes de acción y emitir órdenes para sus subordinados.

Además, estos usuarios son responsables de la gestión administrativa de sus unidades, esto incluye la administración de los recursos materiales y financieros, la supervisión de la logística, y el bienestar, la capacitación y la disciplina de sus subordinados. Estos usuarios manejarían, en su mayoría, un nivel técnico de persona común pero también el de experto en negocio.

Subalterno

Este usuario engloba a los subalternos de la FAU, estos usuarios llevan a cabo las órdenes de los oficiales, realizando las tareas operativas, técnicas y prácticas. Este grupo se encarga de manejar el armamento, operar y mantener los equipos, conducir los vehículos y ejecutar las tácticas de combate, asegurando que los planes se efectúen de forma efectiva. Estos usuarios manejarían, en su mayoría, un nivel técnico de persona común.

Usuarios

Profesor

Este usuario engloba principalmente a profesores de la EMA o ECEMA que requieran información de los documentos almacenados. Estos usuarios podrán consultar de manera normal los documentos o crear grupos con profesores o estudiantes para el estudio de documentos importantes. Estos usuarios manejarían, en su mayoría, un nivel técnico de persona común.

Estudiante

Este usuario engloba principalmente a estudiantes de la EMA o ECEMA que requieran información de los documentos almacenados. Estos usuarios podrán consultar de manera normal los documentos o crear grupos con otros estudiantes o profesor para el estudio de documentos importantes. Estos usuarios manejarían, en su mayoría, un nivel técnico de persona común.

Entornos de los usuarios

Actualmente los usuarios cuentan con un sistema de directorios local convencional disperso donde almacenan los documentos. Aparte de esto, no cuentan con ninguna herramienta para la gestión de documentos. Para el acceso a este sistema de directorios los usuarios se conectan o de manera local o a través de una VPN.

Para la realización de tareas referente a documentos suelen estar involucrados un grupo de personas de uno o muchos departamentos con diferentes rangos.

Los usuarios además cuentan con un sistema LDAP donde tienen su información personal, así como rango y departamento.

Identificación de necesidades clave

La dispersión actual de esta documentación dificulta el acceso eficiente a la información, esto se debe a una falta de organización para el almacenamiento de documentos inicialmente que permitió que se llegara al punto actual.

Actualmente, para acceder a la información, el interesado debe buscar en los diferentes directorios donde podrían estar alojados los documentos de interés; el interesado precisa que los documentos se unifiquen en un único directorio o sistema.

Si una persona quiere acceder a información de muchos documentos distintos, deberá buscarlos todos manualmente, dado que actualmente se utiliza sólo un sistema de directorios

convencional. A esta, le interesa un sistema que le permita acceder tanto a la información como a los múltiples documentos fácilmente.

Si una persona no sabe dónde buscar un documento de interés o documentos relacionados, de alguna forma u otra requerirá ayuda de algún compañero o superior que le enseñe cómo y dónde buscar. A esta, le interesa un sistema que le permita la búsqueda de documentos de interés y documentos relacionados sin la necesidad de requerir ayuda de otra persona.

Resumen del producto

Contexto del producto

El sistema se integra con el LDAP propio de la FAU para la autenticación de los usuarios y la sincronización automática de sus perfiles de seguridad. La seguridad del sistema se basa en un modelo híbrido: la autenticación y el control de operaciones de gestión se resuelven mediante tokens JWT bajo un esquema de control de acceso basado en roles (RBAC); mientras que el acceso a los documentos y las respuestas del modelo se restringen estrictamente mediante un esquema de control de acceso obligatorio (MAC), el cual valida dinámicamente los niveles de clasificación de seguridad y compartimentos.

Debido a que el sistema debe ser desarrollado y operado localmente en su totalidad, no realiza llamadas a servicios externos en Internet. En particular, la ejecución del modelo de lenguaje se ejecuta en infraestructura propia mediante el motor Ollama, lo que garantiza que ninguna consulta ni documento abandone la red de la FAU. Esta restricción de operación 100% local se verificó sobre la implementación y constituye uno de los pilares de la propuesta de valor.

Resumen de capacidades

Beneficio para el cliente	Característica que produce el beneficio
Un usuario sabrá donde tanto buscar como guardar cualquier documento de importancia.	Sistema unificado para almacenamiento de documentos.
El usuario se ahorra tiempo y esfuerzo buscando entre todos los documentos la información que busca.	Capacidad de búsqueda de información de documentos desconocidos.

El usuario puede trabajar o investigar colaborativamente con otros usuarios fácilmente.	Creación de grupos con otros usuarios donde pueden ver su consultas y las respuestas del sistema.
El cliente puede eventualmente escalar el sistema con más funcionalidades.	Documentación y código desarrollados con enfoque en entendimiento de alguien ajeno al sistema.
Un usuario no accederá a información restringida de manera no intencionada.	El sistema restringirá el acceso a documentos en base a roles y permisos.
Al usuario le resulta intuitivo y se reduce el tiempo de adopción con el sistema.	Interfaz intuitiva y similar a otros productos del mercado.

Asunciones y dependencias

- Asumimos que la FAU tiene la capacidad de costear el hardware requerido para el funcionamiento del sistema.
- Asumimos que la FAU se encargará de la instalación del sistema en su entorno uno vez se haya provisto.

Costos y precios

Se realizó un análisis comparativo de diversos modelos de lenguaje detallados en el documento de Diseño. A partir de dicho análisis, el documento de Plan de Proyecto incluye la sección de “Recomendaciones de Hardware”, que especifica las configuraciones mínima y recomendada del servidor principal (procesador, GPU/VRAM, memoria, almacenamiento y red) y de los equipos cliente.

El costo principal del proyecto, desde la perspectiva de la FAU, es por lo tanto la adquisición del hardware del servidor donde corre el modelo. El sistema admite dos perfiles de despliegue: una variante sobre GPU, recomendada para tiempos de respuesta de producción, y una variante sobre CPU, viable con modelos livianos para entornos de menores recursos o de prueba. La adquisición del hardware especificado correrá por parte de la FAU.

Instalación

El sistema se distribuye en contenedores y se despliega mediante Docker Compose (para desarrollo/pruebas) o Docker Swarm (para entornos de producción y alta disponibilidad), organizándose en tres conjuntos principales:

1. **Infraestructura:** Bases de datos PostgreSQL, Redis, RabbitMQ, almacenamiento de objetos MinIO, motor de modelos Ollama y Neo4j.
2. **Servicios de la aplicación:** Los microservicios del sistema (gateway, auth-service, chat-service, llm-service, document-processing-service, document-collection-service y notification-service) más el worker de notificaciones (notification-worker), con variantes de despliegue para entornos con CPU o con GPU.
3. **Observabilidad:** Prometheus, Grafana, Elasticsearch, Filebeat y Arize Phoenix (para el rastreo y evaluación de ejecuciones del LLM).

El despliegue es completamente local, sin dependencias de servicios en Internet. El procedimiento detallado de instalación y configuración se entregará como manual en la fase de Transición.

Alternativas competitivas

Personal especializado en la gestión de documentos

Esta alternativa propondría que haya una parte del personal que esté especializado en la gestión de documentos y que otros usuarios le deleguen la búsqueda de los documentos.

Esta alternativa requeriría mucho menor costo comparado con un sistema informático especializado en gestión y tomaría menor tiempo en ser implementado.

Las desventajas de este sistema es que requeriría un aumento del personal o tomar personal de otras áreas para este propósito que además no es fácilmente escalable. De la mano con lo último, como la búsqueda de documentos no es una actividad tan recurrente, tendrían una alta cantidad de tiempo inactivo.

Sistema de gestión de documentos basado en texto y atributos

Esta alternativa propondría un sistema de gestión de documentos que permita la búsqueda de documentos a través del texto dentro de los mismos o atributos que se le asignen al momento de subirlos.

Esta alternativa requeriría menor costo comparado con un sistema basado en IA y tomaría menor tiempo en ser implementado. Además, este sistema podría ser útil cuando la persona conozca algo del texto del documento que está buscando.

Las desventajas de este sistema es que uno no siempre se puede fiar en la búsqueda por texto, dado que la concepción del usuario del texto que tendría que tener el documento puede no ser correcta y, al final del día, la capacidad de un usuario de encontrar documentos en base a texto y atributos va a depender de su competencia en buscarlos correctamente. Este sistema, además, sería menos escalable comparado al sistema planteado actual.

Restricciones

El sistema debe desarrollarse y operarse de forma exclusivamente local, sin interacción con ningún otro sistema en Internet. Esta restricción se verificó sobre la implementación: la inferencia del modelo de lenguaje se realiza mediante Ollama dentro de la propia red, y el resto de los componentes (bases de datos, almacenamiento de objetos, colas de mensajes, observabilidad) se despliegan localmente. La integración con el LDAP institucional se encuentra implementada en el servicio de autenticación (aura-auth-service) para gestionar el acceso de los usuarios y sincronizar sus permisos y nivel de clasificación de forma local dentro de la red de la FAU.

Rangos de calidad

Los rangos de calidad y desempeño esperados se alinean con los criterios de aceptación definidos en el Plan de Proyecto, que abarcan la calidad de las respuestas de la IA (evaluada mediante la biblioteca Ragas (usando métricas locales de fidelidad, relevancia y recuperación de contexto con un LLM local como juez) y monitoreada con Arize Phoenix), el tiempo de respuesta ante consultas (verificable con los tableros de Prometheus, Grafana y el rastreo de latencias en Arize Phoenix), la disponibilidad y robustez ante cortes de conexión, y la correcta aplicación del control de acceso por roles, permisos y clasificación. Los valores numéricos concretos de cada criterio se fijan en ese documento, y su verificación se documenta en los casos de prueba del Plan de Pruebas.

Precedencia y prioridad

La precedencia y prioridad de las funcionalidades se desprende de los documentos de Casos de Uso de Usuario y Casos de Uso de Administrador, donde cada caso de uso se asocia a su prioridad de implementación. En términos generales, el orden de prioridad es: consulta sobre documentos con control de acceso, colaboración en chats, generación de documentación operativa (reportes y checklists) y asistentes configurables, y capacidades de administración y de analítica.

Otros requerimientos del producto

Estándares aplicables

Posiblemente sujeto a alguna legislación de tratamiento de documentos confidenciales relacionados a la FAU en el transcurso del proyecto.

Requerimientos del sistema

Hardware con la capacidad de soportar la ejecución del modelo de lenguaje y del resto de los componentes, según las configuraciones mínima y recomendada especificadas en la sección "Recomendaciones de Hardware" del Plan de Proyecto.

Requerimientos de rendimiento

Los requerimientos de rendimiento se corresponden con los criterios de tiempo de respuesta y calidad descritos en la sección de "Rangos de calidad" y fijados en el Plan de Proyecto, y se verifican mediante los casos de prueba de rendimiento previstos en el Plan de Pruebas y las herramientas de observabilidad desplegada.

Requerimientos de documentación

Como el sistema se planea sea usado y eventualmente expandido por la FAU, el código debe estar desarrollado y documentado de forma que provea la menor dificultad a la hora de comprender su funcionamiento.

Manual del Usuario

Se entregará en la fase de Transición un plan de capacitación y manual de usuario que cubra las funcionalidades de los perfiles de usuario y de administrador.

Ayuda en línea

La interfaz incorpora mensajes de error y confirmaciones descriptivas en cada flujo. No se prevé un módulo de ayuda en línea integrado para el alcance actual, su incorporación queda planteada como mejora futura, apoyada en el manual de usuario.

Guías de instalación y configuración

Se entregará en la fase de Transición una guía de instalación y configuración dirigida al personal técnico de la FAU, que documente: los requisitos de hardware (según las "Recomendaciones de Hardware" del Plan de Proyecto), el despliegue mediante Docker Compose descrito en la sección de "Instalación" (incluyendo la elección entre las variantes CPU y GPU), la

configuración de variables de entorno y credenciales de cada servicio, la integración y sincronización de usuarios y roles con el LDAP institucional, y los procedimientos básicos de operación (respaldos de las bases de datos PostgreSQL, Neo4j y Redis, y del almacenamiento de objetos MinIO), y el monitoreo del sistema mediante los tableros de observabilidad (Prometheus, Grafana, Elasticsearch, Filebeat y Arize Phoenix).