

Proyecto AURA

Recomendaciones de Hardware



Integrantes:

Bruno Albín
Ignacio Villarreal
Santiago Aurrecochea
Emiliano Fau

Tutor:

Bernardo Rychtenberg

1 de julio de 2026

Índice

1	Riesgo Asociado	1
2	Recomendaciones para el servidor principal	1
2.1	CPU	1
2.2	GPU	1
2.3	Memoria RAM	2
2.4	Almacenamiento	2
3	Conclusión	2

1. Riesgo Asociado

Esta sección forma parte del plan de mitigación del riesgo identificado como “**Insuficiencia de capacidad de hardware**” en el registro de riesgos del proyecto AURA. El objetivo es establecer los requisitos mínimos y recomendados de hardware para que el sistema opere correctamente en la infraestructura propia de la Fuerza Aérea del Uruguay (FAU), considerando que el modelo de lenguaje (LLM) corre de forma local y que se estiman menos de 20 usuarios concurrentes.

2. Recomendaciones para el servidor principal

El servidor principal es el equipo que ejecuta el backend, el modelo LLM y la base de datos PostgreSQL con PGVector. Es el componente crítico del sistema.

2.1. CPU

Componente	Mínimo	Recomendado	Notas
Procesador	8 núcleos / 16 hilos	16 núcleos / 32 hilos	El LLM usa CPU si no hay GPU suficiente. Más núcleos mejoran la inferencia y el procesamiento paralelo de consultas.
Frecuencia	2.5 GHz base	3.0 GHz base o superior	Mayor frecuencia mejora la latencia en consultas individuales.

2.2. GPU

Componente	Mínimo	Recomendado	Notas
VRAM	16 GB	24 GB o más	
Modelo GPU	NVIDIA RTX 3050	RTX 5070 TI	

2.3. Memoria RAM

Componente	Mínimo	Recomendado	Notas
Capacidad RAM	16 GB	32 GB	El sistema operativo, el backend, PostgreSQL y el proceso de inferencia compiten por RAM. Con menos de 16 GB se producen swaps que afectan el rendimiento.
Tipo	DDR4 ECC	DDR5 ECC	ECC (Error Correcting Code) previene corrupción silenciosa de datos.
Frecuencia	2666 MHz	3200 MHz o superior	Mayor ancho de banda de memoria mejora la transferencia de datos al modelo.

2.4. Almacenamiento

Componente	Mínimo	Recomendado	Notas
Disco del sistema	256 GB SSD NVMe	512 GB SSD NVMe	El sistema operativo, los modelos LLM y los índices vectoriales deben estar en SSD.
Disco de datos	256 GB HDD o SSD	512 GB SSD SATA	Para almacenar los documentos de la FAU, base de datos y logs del sistema.

3. Conclusión

Las recomendaciones anteriores se fundamentan en la evaluación comparativa de modelos de lenguaje documentada junto al código del sistema, donde se detalla el tamaño, los parámetros, la ventana de contexto y los requerimientos de memoria de los modelos considerados (familias Gemma, Qwen, Llama, Mistral y DeepSeek-R1, incluyendo variantes cuantizadas Q4 que corren en 8 GB de VRAM). Esa tabla justifica directamente los rangos de VRAM y almacenamiento recomendados en esta sección.

El despliegue contempla ambas configuraciones mediante Docker Compose:

- **Una variante GPU** de los servicios, con aceleración CUDA para la inferencia y la generación de embeddings.
- **Una variante CPU**, que permite operar el sistema con modelos livianos a costa de mayores tiempos de respuesta.

Esta dualidad es, en sí misma, una medida de mitigación del riesgo de hardware: le permite a la FAU comenzar a operar con equipamiento existente y escalar a una configuración GPU cuando el volumen de uso lo justifique.